Министерство образования и науки Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

Факультет «Информатика и системы управления» (ИУ)

Кафедра «Информационные системы и телекоммуникации» (ИУ3)

Отчет

по лабораторной работе № 3

по курсу «Технологии машинного обучения»

Выполнил: Суржиков Л.А.

Группа: ИУ3С-51Б

Проверил: Ю.Е.Гапанюк

Москва, 2026 г.

1. Описание задания

Ссылка на постановку задания:

- https://github.com/ugapanyuk/courses_current/wiki/LAB_TMO__KNN

Цель лабораторной работы:

изучение способов подготовки выборки и подбора гиперпараметров на примере метода ближайших соседей.

Задание:

- Выберите набор данных (датасет) для решения задачи классификации или регрессии.
- В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- С использованием метода train_test_split разделите выборку на обучающую и тестовую.
- Обучите модель ближайших соседей для произвольно заданного гиперпараметра K. Оцените качество модели с помощью подходящих для задачи метрик.
- Произведите подбор гиперпараметра K с использованием GridSearchCV и RandomizedSearchCV и кросс-валидации, оцените качество оптимальной модели. Используйте не менее двух стратегий кросс-валидации.
- Сравните метрики качества исходной и оптимальной моделей.

Требования к отчёту:

Отчёт по лабораторной работе должен содержать:

- титульный лист;
- описание задания;
- текст программы;
- экранные формы с примерами выполнения программы.

В случае использования ноутбуков фрагменты «текст программы» и «экранные формы» соответствуют ячейкам ноутбуков.

Выбранный датасет:

Loan Prediction Problem Dataset («Прогнозирование одобрения кредита», Kaggle) — 614 заявок клиентов на получение кредита, тот же датасет, что и в лабораторной работе № 2. Решается задача бинарной классификации: по анкетным данным клиента (пол, семейное положение, иждивенцы, образование, самозанятость, доходы, сумма и

срок кредита, кредитная история, район) предсказать целевой признак Loan_Status — будет ли кредит одобрен.

2. Текст программы и экранные формы с примерами выполнения

Ниже приведены фрагменты кода ноутбука LAB3_knn_loan.ipynb и результаты их выполнения (текстовый вывод и графики). Фрагменты идут в порядке ячеек ноутбука.

Фрагмент 1 — Подключение библиотек

Код:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib
import seaborn as sns

from sklearn.impute import SimpleImputer
from sklearn.preprocessing import LabelEncoder, OrdinalEncoder, StandardScaler
from sklearn.model_selection import train_test_split, KFold, StratifiedKFold, ShuffleSplit
from sklearn.model_selection import GridSearchCV, RandomizedSearchCV, cross_val_score
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score
from sklearn.metrics import roc_auc_score, confusion_matrix, classification_report

matplotlib.rcParams["font.family"] = "DejaVu Sans"
matplotlib.rcParams["axes.unicode_minus"] = False

# палитра как в прошлых лабах
BLUE_DARK = "#1B3B6F"
BLUE = "#3B6EA5"
BLUE_LIGHT = "#8FB8D9"
RED_DARK = "#7A1F2B"
RED = "#B23A48"
RED_LIGHT = "#E0949C"
```

Фрагмент 2 — 2. Набор данных

Код:

```
df = pd.read_csv("loan_prediction.csv")
print("Размер:", df.shape)
df.head()
```

Результат выполнения:

```
Размер: (614, 13)

    Loan_ID Gender Married Dependents     Education Self_Employed  \
0  LP001002   Male      No          0      Graduate            No
1  LP001003   Male     Yes          1      Graduate            No
2  LP001005   Male     Yes          0      Graduate           Yes
3  LP001006   Male     Yes          0  Not Graduate            No
4  LP001008   Male      No          0      Graduate            No
```

```
   ApplicantIncome  CoapplicantIncome  LoanAmount  Loan_Amount_Term  \
0             5849                0.0         NaN             360.0
1             4583             1508.0       128.0             360.0
2             3000                0.0        66.0             360.0
3             2583             2358.0       120.0             360.0
4             6000                0.0       141.0             360.0

   Credit_History Property_Area Loan_Status
0             1.0         Urban           Y
1             1.0         Rural           N
2             1.0         Urban           Y
3             1.0         Urban           Y
4             1.0         Urban           Y
```

Фрагмент 3 — 2. Набор данных

Код:

```
print("Распределение целевого признака:")
print(df["Loan_Status"].value_counts())
print()
print((df["Loan_Status"].value_counts(normalize=True) * 100).round(1))
```

Результат выполнения:

```
Распределение целевого признака:
Loan_Status
Y    422
N    192
Name: count, dtype: int64

Loan_Status
Y    68.7
N    31.3
Name: proportion, dtype: float64
```

Фрагмент 4 — 3. Предобработка данных (пропуски и категориальные признаки)

Код:

```
data = df.drop(columns=["Loan_ID"])

# пропуски: LoanAmount - медианой, остальное - модой (как в ЛР2)
data[["LoanAmount"]] = SimpleImputer(strategy="median").fit_transform(data[["LoanAmount"]])
mode_cols = ["Gender", "Married", "Dependents", "Self_Employed", "Loan_Amount_Term",
"Credit_History"]
data[mode_cols] = SimpleImputer(strategy="most_frequent").fit_transform(data[mode_cols])

# кодирование категориальных признаков
for col in ["Gender", "Married", "Education", "Self_Employed", "Loan_Status"]:
    data[col] = LabelEncoder().fit_transform(data[col])
data["Dependents"] = OrdinalEncoder(categories=[["0", "1", "2",
"3+"]]).fit_transform(data[["Dependents"]])
data = pd.get_dummies(data, columns=["Property_Area"], prefix="Area", dtype=int)
data = data.astype(float)

print("Пропусков:", data.isnull().sum().sum())
data.head()
```

Результат выполнения:

```
Пропусков: 0

   Gender  Married  Dependents  Education  Self_Employed  ApplicantIncome  \
0     1.0      0.0         0.0        0.0            0.0           5849.0
1     1.0      1.0         1.0        0.0            0.0           4583.0
2     1.0      1.0         0.0        0.0            1.0           3000.0
3     1.0      1.0         0.0        1.0            0.0           2583.0
4     1.0      0.0         0.0        0.0            0.0           6000.0

   CoapplicantIncome  LoanAmount  Loan_Amount_Term  Credit_History  \
0                0.0       128.0             360.0             1.0
1             1508.0       128.0             360.0             1.0
2                0.0        66.0             360.0             1.0
3             2358.0       120.0             360.0             1.0
4                0.0       141.0             360.0             1.0

   Loan_Status  Area_Rural  Area_Semiurban  Area_Urban
0          1.0         0.0             0.0         1.0
1          0.0         1.0             0.0         0.0
2          1.0         0.0             0.0         1.0
3          1.0         0.0             0.0         1.0
4          1.0         0.0             0.0         1.0
```

Фрагмент 5 — 4. Разделение на обучающую и тестовую выборки

Код:

```
X = data.drop(columns=["Loan_Status"])
y = data["Loan_Status"].astype(int)

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.25, random_state=1, stratify=y)

print("Обучающая выборка:", X_train.shape, " Тестовая выборка:", X_test.shape)
print("Доля класса 1 в train:", round(y_train.mean(), 3), " в test:", round(y_test.mean(), 3))
```

Результат выполнения:

```
Обучающая выборка: (460, 13)  Тестовая выборка: (154, 13)
Доля класса 1 в train: 0.687  в test: 0.688
```

Фрагмент 6 — 4. Разделение на обучающую и тестовую выборки

Код:

```
scaler = StandardScaler()
X_train_sc = scaler.fit_transform(X_train)
X_test_sc = scaler.transform(X_test)

pd.DataFrame(X_train_sc, columns=X.columns).describe().loc[["mean", "std"]].round(2)
```

Результат выполнения:

```
      Gender  Married  Dependents  Education  Self_Employed  ApplicantIncome  \
mean    -0.0     -0.0        -0.0       -0.0           -0.0              0.0
std      1.0      1.0         1.0        1.0            1.0              1.0
```

```
      CoapplicantIncome  LoanAmount  Loan_Amount_Term  Credit_History  \
mean                0.0        -0.0              -0.0             0.0
std                 1.0         1.0               1.0             1.0

      Area_Rural  Area_Semiurban  Area_Urban
mean         0.0             0.0         0.0
std          1.0             1.0         1.0
```

Фрагмент 7 — 5. Модель ближайших соседей для произвольного K

Код:

```
def print_metrics(y_true, y_pred, y_proba):
    res = {
        "Accuracy": accuracy_score(y_true, y_pred),
        "Precision": precision_score(y_true, y_pred),
        "Recall": recall_score(y_true, y_pred),
        "F1": f1_score(y_true, y_pred),
        "ROC-AUC": roc_auc_score(y_true, y_proba),
    }
    for k, v in res.items():
        print(f"{k:10} {v:.4f}")
    return res
```

Фрагмент 8 — 5. Модель ближайших соседей для произвольного K

Код:

```
knn_3 = KNeighborsClassifier(n_neighbors=3)
knn_3.fit(X_train_sc, y_train)

pred_3 = knn_3.predict(X_test_sc)
proba_3 = knn_3.predict_proba(X_test_sc)[:, 1]

print("KNN, K = 3, тестовая выборка:")
metrics_3 = print_metrics(y_test, pred_3, proba_3)
```

Результат выполнения:

```
KNN, K = 3, тестовая выборка:
Accuracy   0.7662
Precision  0.7869
Recall     0.9057
F1         0.8421
ROC-AUC    0.7074
```

Фрагмент 9 — 5. Модель ближайших соседей для произвольного K

Код:

```
print(classification_report(y_test, pred_3, target_names=["отказ (0)", "одобрен (1)"]))
```

Результат выполнения:

```
              precision    recall  f1-score   support

   отказ (0)       0.69      0.46      0.55        48
 одобрен (1)       0.79      0.91      0.84       106
```

```
    accuracy                           0.77       154
   macro avg       0.74      0.68      0.70       154
weighted avg       0.76      0.77      0.75       154
```

Фрагмент 10 — 6.1. Стратегии кросс-валидации

Код:

```
k_range = np.arange(1, 51)
params = {"n_neighbors": k_range}

cv_strategies = {
    "KFold (5)": KFold(n_splits=5, shuffle=True, random_state=1),
    "StratifiedKFold (5)": StratifiedKFold(n_splits=5, shuffle=True, random_state=1),
    "ShuffleSplit (10)": ShuffleSplit(n_splits=10, test_size=0.25, random_state=1),
}

# пример: оценка модели с K = 3 разными стратегиями кросс-валидации
for name, cv in cv_strategies.items():
    scores = cross_val_score(KNeighborsClassifier(n_neighbors=3), X_train_sc, y_train, cv=cv,
scoring="f1")
    print(f"{name:20} F1 по фолдам: {np.round(scores, 3)}  среднее = {scores.mean():.4f}")
```

Результат выполнения:

```
KFold (5)            F1 по фолдам: [0.823 0.844 0.767 0.865 0.884]  среднее = 0.8367
StratifiedKFold (5)  F1 по фолдам: [0.826 0.803 0.803 0.887 0.863]  среднее = 0.8365
ShuffleSplit (10)    F1 по фолдам: [0.836 0.82  0.838 0.844 0.873 0.798 0.83  0.833 0.838 0.872]
среднее = 0.8383
```

Фрагмент 11 — 6.2. GridSearchCV

Код:

```
grid_results = {}
for name, cv in cv_strategies.items():
    gs = GridSearchCV(KNeighborsClassifier(), params, cv=cv, scoring="f1")
    gs.fit(X_train_sc, y_train)
    grid_results[name] = gs
    print(f"{name:20} лучшее K = {gs.best_params_['n_neighbors']:2}, F1 на кросс-валидации =
{gs.best_score_:.4f}")
```

Результат выполнения:

```
KFold (5)            лучшее K = 12, F1 на кросс-валидации = 0.8645

StratifiedKFold (5)  лучшее K = 16, F1 на кросс-валидации = 0.8640

ShuffleSplit (10)    лучшее K = 14, F1 на кросс-валидации = 0.8624
```

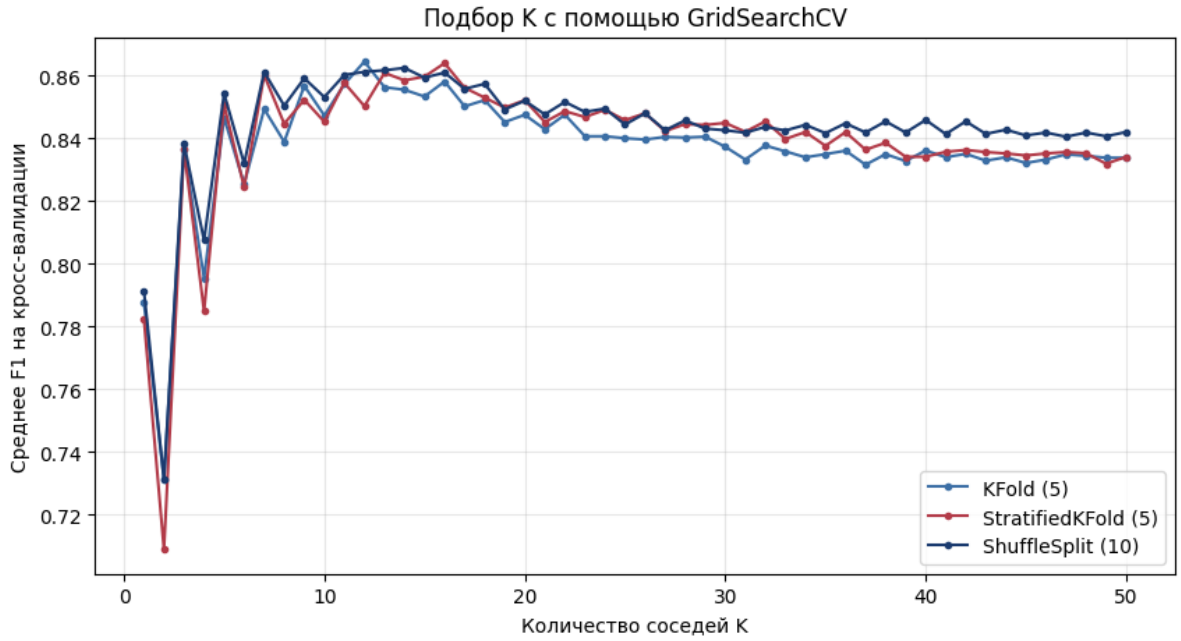
Фрагмент 12 — 6.2. GridSearchCV

Код:

```
plt.figure(figsize=(10, 5))
colors = [BLUE, RED, BLUE_DARK]
for (name, gs), c in zip(grid_results.items(), colors):
    plt.plot(k_range, gs.cv_results_["mean_test_score"], marker="o", markersize=3, color=c,
label=name)
```

```
plt.xlabel("Количество соседей K")
plt.ylabel("Среднее F1 на кросс-валидации")
plt.title("Подбор K с помощью GridSearchCV")
plt.legend()
plt.grid(alpha=0.3)
plt.show()
```

Результат выполнения:



Фрагмент 13 — 6.3. RandomizedSearchCV

Код:

```
rand_results = {}
for name, cv in cv_strategies.items():
    rs = RandomizedSearchCV(KNeighborsClassifier(), params, n_iter=15, cv=cv, scoring="f1",
random_state=1)
    rs.fit(X_train_sc, y_train)
    rand_results[name] = rs
    print(f"{name:20} лучшее K = {rs.best_params_['n_neighbors']:2}, F1 на кросс-валидации =
{rs.best_score_:.4f}")
    print(" " * 21, "проверенные K:", sorted(rs.cv_results_["param_n_neighbors"].data.tolist()))
```

Результат выполнения:

```
KFold (5)            лучшее K = 22, F1 на кросс-валидации = 0.8475
                      проверенные K: [3, 4, 20, 22, 28, 30, 32, 33, 36, 37, 39, 40, 41, 47, 49]
StratifiedKFold (5)  лучшее K = 20, F1 на кросс-валидации = 0.8522
                      проверенные K: [3, 4, 20, 22, 28, 30, 32, 33, 36, 37, 39, 40, 41, 47, 49]

ShuffleSplit (10)    лучшее K = 20, F1 на кросс-валидации = 0.8520
                      проверенные K: [3, 4, 20, 22, 28, 30, 32, 33, 36, 37, 39, 40, 41, 47, 49]
```

Фрагмент 14 — 6.4. Оценка оптимальной модели

Код:

```
best_k = grid_results["StratifiedKFold (5)"].best_params_["n_neighbors"]
print("Оптимальное K =", best_k)

knn_best = KNeighborsClassifier(n_neighbors=best_k)
knn_best.fit(X_train_sc, y_train)

pred_best = knn_best.predict(X_test_sc)
proba_best = knn_best.predict_proba(X_test_sc)[:, 1]

print(f"KNN, K = {best_k}, тестовая выборка:")
metrics_best = print_metrics(y_test, pred_best, proba_best)
```

Результат выполнения:

```
Оптимальное K = 16
KNN, K = 16, тестовая выборка:
Accuracy   0.7987
Precision  0.7737
Recall     1.0000
F1         0.8724
ROC-AUC    0.7254
```

Фрагмент 15 — 7. Сравнение исходной и оптимальной моделей

Код:

```
compare = pd.DataFrame({"K = 3": metrics_3, f"K = {best_k} (оптимальное)":
metrics_best}).round(4)
compare["Разница"] = (compare.iloc[:, 1] - compare.iloc[:, 0]).round(4)
compare
```

Результат выполнения:

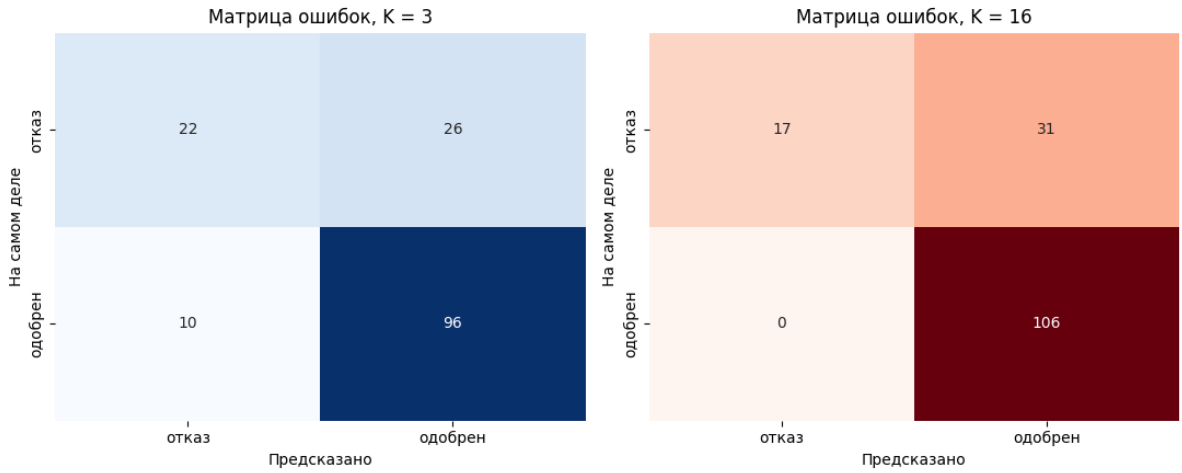
```
            K = 3  K = 16 (оптимальное)  Разница
Accuracy   0.7662                0.7987   0.0325
Precision  0.7869                0.7737  -0.0132
Recall     0.9057                1.0000   0.0943
F1         0.8421                0.8724   0.0303
ROC-AUC    0.7074                0.7254   0.0180
```

Фрагмент 16 — 7. Сравнение исходной и оптимальной моделей

Код:

```
fig, axes = plt.subplots(1, 2, figsize=(11, 4.5))
for ax, pred, title, cmap in [(axes[0], pred_3, "K = 3", "Blues"),
                              (axes[1], pred_best, f"K = {best_k}", "Reds")]:
    cm = confusion_matrix(y_test, pred)
    sns.heatmap(cm, annot=True, fmt="d", cmap=cmap, cbar=False, ax=ax,
                xticklabels=["отказ", "одобрен"], yticklabels=["отказ", "одобрен"])
    ax.set_title("Матрица ошибок, " + title)
    ax.set_xlabel("Предсказано")
    ax.set_ylabel("На самом деле")
plt.tight_layout()
plt.show()
```

Результат выполнения:

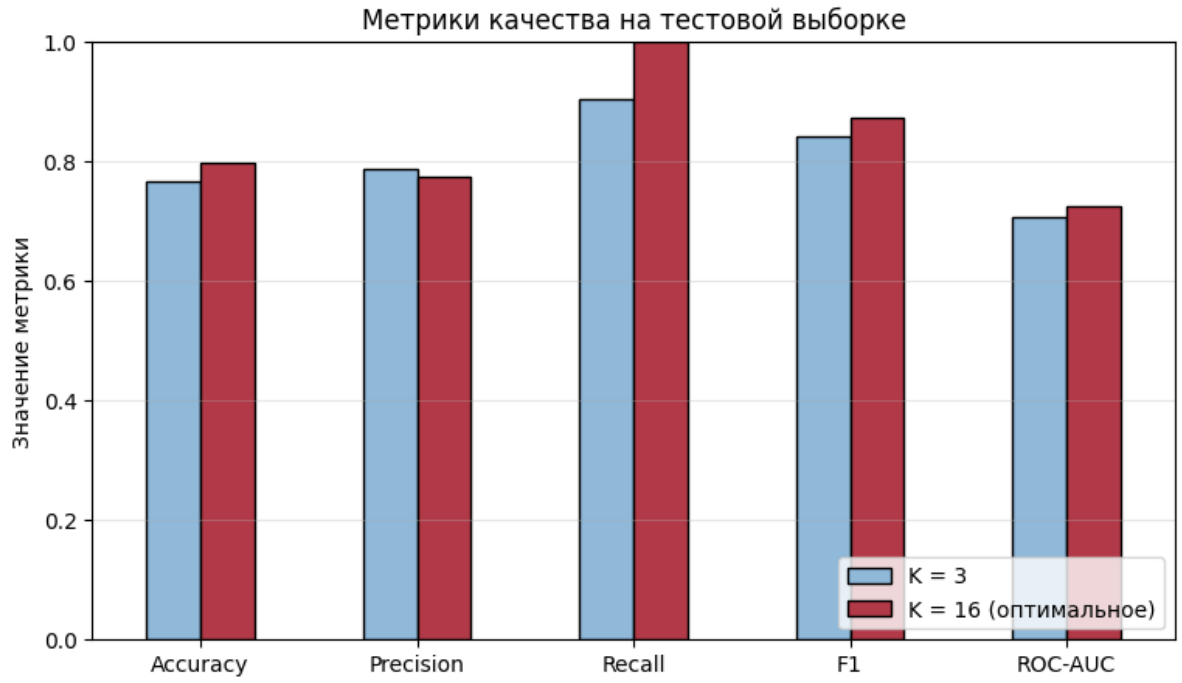


Фрагмент 17 — 7. Сравнение исходной и оптимальной моделей

Код:

```
ax = compare.iloc[:, :2].plot(kind="bar", figsize=(9, 5), color=[BLUE_LIGHT, RED],
edgecolor="black")
plt.title("Метрики качества на тестовой выборке")
plt.ylabel("Значение метрики")
plt.xticks(rotation=0)
plt.ylim(0, 1)
plt.legend(loc="lower right")
plt.grid(axis="y", alpha=0.3)
plt.show()
```

Результат выполнения:



3. Выводы

1. Для задачи бинарной классификации выбран финансовый датасет заявок на кредит (614 записей). Пропуски заполнены медианой и модой, категориальные признаки закодированы, признаки отмасштабированы StandardScaler (scaler обучен только на обучающей выборке).

2. Выборка разделена методом train_test_split в соотношении 75/25 со стратификацией: доля одобренных заявок в обучающей и тестовой выборках одинаковая (≈ 0,69).

3. Модель KNN с произвольным K = 3 на тестовой выборке дала accuracy 0,766, F1 0,842, ROC-AUC 0,707. Модель плохо распознаёт отказы: recall класса «отказ» всего 0,46.

4. Подбор K выполнен с помощью GridSearchCV и RandomizedSearchCV с тремя стратегиями кросс-валидации (KFold, StratifiedKFold, ShuffleSplit). GridSearchCV нашёл K = 12–16 (F1 ≈ 0,86), RandomizedSearchCV — K = 20–22: он проверил только 15 случайных значений, и диапазон 12–16 в них не попал.

5. Оптимальная модель (K = 16) на тестовой выборке лучше исходной: accuracy выросла с 0,766 до 0,799, F1 — с 0,842 до 0,872, ROC-AUC — с 0,707 до 0,725. Но по матрице ошибок видно, что модель с K = 16 чаще одобряет кредит: отказов она распознаёт меньше (17 из 48 против 22 при K = 3). При малом K модель переобучается на шум, при большом K предсказание сглаживается, поэтому подбор гиперпараметра с кросс-валидацией повышает качество.